

# **BÁO CÁO THỰC HÀNH**

## **Logistic Regression, kNN, Decision Tree, Random Forest**

Bài toán phân loại nhị phân trên bộ dữ liệu  
Breast Cancer Wisconsin Diagnostic

MSSV: 24678681

Môn học: Máy học

Thư mục nộp bài: 24678681\_TH\_PhanLoai

## 1. Bài toán và dữ liệu

Mục tiêu của bài thực hành là xây dựng và so sánh bốn mô hình phân loại nhị phân — Logistic Regression, k-Nearest Neighbors (kNN), Decision Tree và Random Forest — trên cùng một bộ dữ liệu, sử dụng cross-validation để lựa chọn siêu tham số một cách khách quan, và đánh giá công bằng trên một tập kiểm tra (test) độc lập chỉ được sử dụng đúng một lần. Bài toán hướng đến việc hỗ trợ chẩn đoán ung thư vú: phân biệt khối u ác tính (malignant) và khối u lành tính (benign) dựa trên 30 đặc trưng số học được trích xuất từ ảnh sinh thiết tế bào.

Bộ dữ liệu sử dụng là Breast Cancer Wisconsin Diagnostic, được nạp trực tiếp từ `sklearn.datasets.load_breast_cancer`, gồm 569 mẫu và 30 đặc trưng số liên tục (bán kính, chu vi, diện tích, độ mịn, độ lõm... ở ba mức thống kê mean, error và worst). Theo quy ước gốc của Scikit-learn, nhãn 0 tương ứng malignant và nhãn 1 tương ứng benign; trong bài thực hành này, nhãn được mã hóa lại sao cho malignant = 1 để lớp dương (positive class) khớp với lớp mà các hàm Precision/Recall/F1 mặc định của Scikit-learn nhắm tới (xem câu trả lời 1 ở Phụ lục).

Về phân bố lớp: 212 mẫu (37.26%) thuộc lớp malignant và 357 mẫu (62.74%) thuộc lớp benign, tỷ lệ khoảng 1.68:1. Đây là mức mất cân bằng lớp nhẹ — chưa nghiêm trọng đến mức phải áp dụng các kỹ thuật lấy mẫu lại (oversampling/undersampling), nhưng đủ để khiến Accuracy có thể gây hiểu lầm nếu sử dụng làm chỉ số duy nhất, vì một mô hình luôn dự đoán benign vẫn đạt Accuracy khoảng 62.7% dù không phát hiện được bất kỳ ca ác tính nào. Kiểm tra chất lượng dữ liệu cho thấy toàn bộ 30 đặc trưng đều là kiểu số thực (float), không có giá trị thiếu và không có dòng dữ liệu trùng lặp, cho thấy dữ liệu đã được chuẩn bị sẵn và không cần các bước làm sạch phức tạp trước khi mô hình hóa (xem Bảng 01, được dẫn xuất và lưu trong `outputs/01_data_overview.csv`).

| Đặc trưng (mẫu)      | Kiểu dữ liệu | Số thiếu | Mean   | Std    | Min    | Max     |
|----------------------|--------------|----------|--------|--------|--------|---------|
| mean radius          | float64      | 0        | 14.13  | 3.52   | 6.98   | 28.11   |
| mean texture         | float64      | 0        | 19.29  | 4.30   | 9.71   | 39.28   |
| mean area            | float64      | 0        | 654.89 | 351.91 | 143.50 | 2501.00 |
| worst radius         | float64      | 0        | 16.27  | 4.83   | 7.93   | 36.04   |
| worst concave points | float64      | 0        | 0.11   | 0.07   | 0.00   | 0.29    |

**Bảng 01 - Trích mẫu từ bảng khảo sát 30 đặc trưng (đầy đủ 30 dòng trong `outputs/01_data_overview.csv`).**

| Lớp               | Số mẫu | Tỉ lệ  |
|-------------------|--------|--------|
| malignant (dương) | 212    | 37.26% |
| benign (âm)       | 357    | 62.74% |
| Tổng              | 569    | 100%   |

**Bảng 02 - Phân bố hai lớp trên toàn bộ dữ liệu (nguồn: `outputs/02_class_distribution.png`).**

## 2. Quy trình

Dữ liệu được chia theo tỷ lệ 80% train / 20% test bằng `train_test_split(test_size=0.20, random_state=42, stratify=y)`, cho ra 455 mẫu train (170 malignant, 285 benign) và 114 mẫu test (42 malignant, 72 benign). Tham số `stratify=y` đảm bảo tỷ lệ malignant/benign trong cả hai tập con đều xấp xỉ tỷ lệ 37.26%/62.74% của toàn bộ dữ liệu, tránh trường hợp

tập test vô tình có phân bố lớp lệch hẳn so với thực tế.

Toàn bộ quá trình tìm kiếm siêu tham số chỉ chạy trên tập train, thông qua *StratifiedKFold*(*n\_splits*=5, *shuffle*=True, *random\_state*=42). Cả bốn thuật toán dùng chung một đối tượng *cv* này để đảm bảo mọi mô hình được đánh giá trên đúng cùng các fold train/validation, giúp việc so sánh công bằng — nếu mỗi mô hình dùng cách chia khác nhau, chênh lệch hiệu năng quan sát được có thể chỉ do khác biệt ngẫu nhiên giữa các lần chia dữ liệu chứ không phản ánh bản chất thuật toán.

Để chống rò rỉ dữ liệu (data leakage), Logistic Regression và kNN được đặt trong *Pipeline* gồm *StandardScaler* rồi mới đến mô hình; nhờ đó, trong mỗi fold của *GridSearchCV*, scaler chỉ được fit trên phần train của fold đó rồi mới transform cả phần train và validation, không bao giờ scaler được fit trên toàn bộ dữ liệu (kể cả tập test) trước khi chia. Decision Tree và Random Forest không cần chuẩn hóa vì các mô hình cây chia dữ liệu dựa trên ngưỡng của từng đặc trưng riêng lẻ, không dựa trên khoảng cách hay tổ hợp tuyến tính có trọng số theo thang đo.

Chỉ số dùng để lựa chọn mô hình/siêu tham số tốt nhất là F1-score của lớp malignant (*refit*='f1' trong *GridSearchCV*), vì F1 cân bằng giữa Precision và Recall, phù hợp hơn Accuracy khi có mất cân bằng lớp. Bên cạnh F1, Accuracy, Precision, Recall và ROC-AUC cũng được ghi nhận đầy đủ để có cái nhìn toàn diện. Nguyên tắc dùng tập test được tuân thủ nghiêm ngặt: tập test không được truyền vào bất kỳ *GridSearchCV* nào và không được dùng để chọn mô hình hay điều chỉnh siêu tham số; mỗi mô hình chỉ được predict trên tập test đúng một lần, ở bước cuối cùng (Mục 5), sau khi mô hình khuyến nghị đã được chốt từ kết quả cross-validation.

### 3. Bốn mô hình

#### 3.1. Logistic Regression

Pipeline: *StandardScaler* → *LogisticRegression*(*max\_iter*=5000, *solver*='liblinear', *random\_state*=42). Không gian tìm kiếm gồm  $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$ , *penalty* ∈ {l1, l2}, *class\_weight* ∈ {None, balanced}, tổng cộng 24 cấu hình. Cấu hình tốt nhất theo F1 CV là  $C = 0.1$ , *penalty* = l2, *class\_weight* = balanced, đạt F1 CV = 0.9674 (std = 0.0109). Tham số *C* là nghịch đảo cường độ điều chuẩn: *C* nhỏ tăng điều chuẩn, ép hệ số về gần 0, giúp mô hình đơn giản hơn và ổn định hơn nhưng có thể underfitting nếu quá nhỏ; *C* lớn giảm điều chuẩn, cho phép hệ số tự do khớp sát dữ liệu train hơn nhưng dễ overfitting. Với  $C = 0.1$  (điều chuẩn tương đối mạnh), mô hình đã đạt hiệu năng CV rất cao, cho thấy các đặc trưng của bộ dữ liệu này có khả năng phân tách tuyến tính tốt sau khi chuẩn hóa. Penalty l2 (được chọn) chỉ thu nhỏ đều các hệ số về gần 0 mà không đưa hẳn về 0, trong khi l1 có thể đưa một số hệ số về đúng 0 (lựa chọn đặc trưng tự động); ở đây l2 cho kết quả CV tốt hơn, hàm ý các đặc trưng đều đóng góp thông tin hữu ích và không cần loại bỏ.

#### 3.2. k-Nearest Neighbors (kNN)

Pipeline: *StandardScaler* → *KNeighborsClassifier*(); chuẩn hóa là bắt buộc vì kNN dựa hoàn toàn trên khoảng cách giữa các điểm dữ liệu. Không gian tìm kiếm: *n\_neighbors* ∈ {3,5,7,9,11,15,21}, *weights* ∈ {uniform, distance}, *p* ∈ {1,2}, tổng 28 cấu hình. Cấu hình tốt nhất là *n\_neighbors* = 3, *weights* = uniform, *p* = 1 (Manhattan), F1 CV = 0.9667 (std = 0.0223). *k* nhỏ (*k* = 3) tạo biên quyết định phức tạp, bias thấp nhưng variance cao — nhạy cảm với nhiễu cục bộ; *k* lớn làm biên quyết định mượt hơn (bias cao, variance thấp) nhưng có thể bỏ sót cấu trúc cục bộ quan trọng. Việc *weights*='uniform' cho kết quả tốt nhất ở đây cho thấy khi *k* đã nhỏ, việc trọng số hóa theo khoảng cách (distance) không mang lại

lợi ích rõ rệt so với coi mọi láng giềng như nhau. Khoảng cách Manhattan ( $p=1$ ) — tổng trị tuyệt đối chênh lệch theo từng chiều — cho kết quả nhìn hơn Euclidean ( $p=2$ ) trên dữ liệu đã chuẩn hóa này, có thể do ít bị chi phối bởi một vài chiều có chênh lệch lớn đơn lẻ.

### 3.3. Decision Tree

DecisionTreeClassifier(random\_state=42), không cần StandardScaler, GridSearchCV chạy trực tiếp trên  $X_{train}$ . Không gian tìm kiếm:  $criterion \in \{gini, entropy\}$ ,  $max\_depth \in \{None, 2, 3, 4, 5, 7, 10\}$ ,  $min\_samples\_split \in \{2, 5, 10\}$ ,  $min\_samples\_leaf \in \{1, 2, 4, 8\}$ ,  $class\_weight \in \{None, balanced\}$ , tổng 336 cấu hình. Cấu hình tốt nhất là  $criterion = gini$ ,  $max\_depth = None$ ,  $min\_samples\_leaf = 4$ ,  $min\_samples\_split = 2$ ,  $class\_weight = balanced$ , F1 CV = 0.9299 (std = 0.0338) — thấp hơn rõ rệt so với Logistic Regression và kNN, đồng thời có độ lệch chuẩn giữa các fold lớn nhất, cho thấy Decision Tree kém ổn định hơn. Dù  $max\_depth$  được chọn là None (không giới hạn), cây thực tế chỉ phát triển sâu 7 tầng nhờ ràng buộc  $min\_samples\_leaf = 4$  đã tự giới hạn độ phức tạp.  $max\_depth$  kiểm soát số tầng phân chia tối đa — giá trị nhỏ giúp cây đơn giản, dễ underfitting; giá trị lớn cho phép cây khớp sát dữ liệu train hơn nhưng dễ overfitting.  $min\_samples\_leaf$  quy định số mẫu tối thiểu tại mỗi lá, đóng vai trò cắt tỉa sớm (pre-pruning): giá trị nhỏ (1) cho phép lá rất thuần khiết nhưng dễ dựa trên vài mẫu đặc biệt (overfitting), giá trị lớn hơn buộc mỗi lá tổng quát hơn.

### 3.4. Random Forest


RandomForestClassifier(random\_state=42, n\_jobs=-1), không chuẩn hóa dữ liệu. Không gian tìm kiếm:  $n\_estimators \in \{100, 300\}$ ,  $max\_depth \in \{None, 5, 10\}$ ,  $max\_features \in \{sqrt, log2\}$ ,  $min\_samples\_leaf \in \{1, 2, 4\}$ ,  $class\_weight \in \{None, balanced\}$ , tổng 72 cấu hình. Cấu hình tốt nhất là  $n\_estimators = 100$ ,  $max\_depth = 5$ ,  $max\_features = sqrt$ ,  $min\_samples\_leaf = 1$ ,  $class\_weight = None$ , F1 CV = 0.9553 (std = 0.0284) — cải thiện đáng kể so với một cây đơn (0.9299) nhờ tổng hợp (bagging) nhiều cây trên các mẫu bootstrap và tập con đặc trưng khác nhau, giúp giảm phương sai.  $n\_estimators = 100$  (không cần 300 cây) đã đủ ổn định trong CV này, cho thấy lợi ích của việc tăng số cây giảm dần sau một ngưỡng nhất định trong khi chi phí tính toán tăng thêm (fit\_time\_mean của Random Forest lớn hơn hẳn ba mô hình còn lại — xem Bảng 15).  $max\_features='sqrt'$  giới hạn số đặc trưng được xét tại mỗi lần chia, tăng tính đa dạng giữa các cây con và giảm tương quan giữa chúng, qua đó tăng hiệu quả giảm phương sai khi tổng hợp.  $class\_weight=None$  được chọn thay vì balanced, hàm ý với mức mất cân bằng lớp nhẹ của bộ dữ liệu này, việc gán trọng số ưu tiên lớp thiểu số không cải thiện thêm F1 CV so với mặc định.

## 4. So sánh CV và chọn mô hình

Bảng 15 tổng hợp cấu hình tốt nhất và các chỉ số CV trung bình (5 fold) của bốn mô hình, còn Hình 16 trực quan hóa F1 CV (kèm error bar  $\pm 1$  độ lệch chuẩn) và ROC-AUC CV của từng mô hình.

| Model               | Accuracy | Precision | Recall | F1 ( $\pm$ std)     | ROC-AUC | Fit time (s) |
|---------------------|----------|-----------|--------|---------------------|---------|--------------|
| Logistic Regression | 0.9758   | 0.9766    | 0.9588 | 0.9674 $\pm$ 0.0109 | 0.9949  | 0.0041       |
| kNN                 | 0.9758   | 0.9877    | 0.9471 | 0.9667 $\pm$ 0.0223 | 0.9834  | 0.0029       |
| Decision Tree       | 0.9473   | 0.9337    | 0.9294 | 0.9299 $\pm$ 0.0338 | 0.9639  | 0.0064       |
| Random Forest       | 0.9670   | 0.9645    | 0.9471 | 0.9553 $\pm$ 0.0284 | 0.9882  | 0.1329       |

**Bảng 15 - So sánh các mô hình bằng cross-validation trên tập train (outputs/15\_cv\_model\_comparison.csv).**



**Hình 16 - F1 CV ( $\pm 1$  std) và ROC-AUC CV của bốn mô hình (outputs/16\_cv\_model\_comparison.png).**


Xét theo tiêu chí đã công bố (F1 CV lớn nhất), Logistic Regression được chọn làm mô hình khuyến nghị với F1 CV = 0.9674, nhỉnh hơn kNN (0.9667) một khoảng rất nhỏ (0.0007), trong khi Random Forest (0.9553) và Decision Tree (0.9299) thấp hơn rõ rệt hơn. Về độ ổn định, Logistic Regression có độ lệch chuẩn F1 giữa các fold thấp nhất (0.0109), cho thấy hiệu năng đồng đều nhất qua các lần chia dữ liệu khác nhau, trong khi Decision Tree có độ lệch chuẩn lớn nhất (0.0338) — dấu hiệu của một mô hình nhạy cảm hơn với cách chia dữ liệu cụ thể. Về khả năng giải thích, Logistic Regression (hệ số) và Decision Tree (luật nếu-thì trực quan) dễ diễn giải hơn Random Forest (tổng hợp hàng trăm cây) và kNN (không có mô hình tường minh, chỉ so sánh khoảng cách). Về chi phí tính toán, Random Forest có fit\_time\_mean (0.1329 giây) lớn hơn hẳn ba mô hình còn lại (đều dưới 0.007 giây), phản ánh chi phí huấn luyện nhiều cây. Vì chênh lệch F1 giữa Logistic Regression và kNN rất nhỏ, có thể coi hai mô hình này gần tương đương về hiệu năng thống kê; tuy nhiên do quy tắc chọn mô hình đã công bố trước (F1 CV lớn nhất, không thay đổi sau khi thấy kết quả), Logistic Regression vẫn được giữ làm mô hình khuyến nghị đi tiếp vào bước đánh giá test.

## 5. Kết quả trên tập test


Bốn best\_estimator\_ (đã fit trên toàn bộ tập train) được dùng để predict trên tập test 114 mẫu đúng một lần duy nhất, không điều chỉnh lại siêu tham số. Bảng 17 tổng hợp kết quả.

| Model               | Accuracy | Precision | Recall | F1     | ROC-AUC | TN | FP | FN | TP |
|---------------------|----------|-----------|--------|--------|---------|----|----|----|----|
| Logistic Regression | 0.9912   | 1.0000    | 0.9762 | 0.9880 | 0.9977  | 72 | 0  | 1  | 41 |
| kNN                 | 0.9649   | 1.0000    | 0.9048 | 0.9500 | 0.9735  | 72 | 0  | 4  | 38 |
| Decision Tree       | 0.9123   | 0.9211    | 0.8333 | 0.8750 | 0.9261  | 69 | 3  | 7  | 35 |
| Random Forest       | 0.9737   | 1.0000    | 0.9286 | 0.9630 | 0.9950  | 72 | 0  | 3  | 39 |

**Bảng 17 - Kết quả đánh giá một lần trên tập test, labels=[0,1] nên TN/FP/FN/TP tương ứng benign/malignant (outputs/17\_test\_metrics.csv). Mỗi hàng có TN+FP+FN+TP = 114.**



**Hình 18 - Confusion matrix của bốn mô hình trên tập test (outputs/18\_confusion\_matrices.png).**



**Hình 19 - ROC curve của bốn mô hình và đường ngẫu nhiên (outputs/19\_roc\_curves.png).**

Trên tập test, Logistic Regression bỏ sót malignant ít nhất ( $FN = 1$ , tức Recall malignant cao nhất = 0.9762), đồng thời đạt F1 (0.9880) và ROC-AUC (0.9977) cao nhất trong bốn mô hình, khớp với kết quả CV đã dự đoán ở Mục 4. Decision Tree có FN cao nhất (7/42 ca malignant bị bỏ sót, Recall chỉ 0.8333) và cũng là mô hình duy nhất có  $FP > 0$  (3 ca benign bị chẩn đoán nhầm thành malignant), phản ánh đúng việc nó có F1 CV và độ ổn định thấp nhất ở bước so sánh CV. kNN và Random Forest có kết quả trung gian, với FN lần lượt là 4 và 3. FN đặc biệt quan trọng trong bài toán này vì mỗi ca malignant bị dự đoán nhầm thành benign đồng nghĩa với việc một bệnh nhân ung thư có thể không được phát hiện và điều trị kịp thời — hậu quả nghiêm trọng hơn nhiều so với FP, vốn chỉ dẫn đến chi phí xét nghiệm bổ sung. Vì vậy, dù Logistic Regression đã có FN thấp nhất, việc tiếp tục theo dõi và cải thiện Recall của lớp malignant vẫn là ưu tiên hàng đầu khi triển khai mô hình trong thực tế.

## 6. Giải thích mô hình

### 6.1. Hệ số Logistic Regression


| Hạng | Đặc trưng       | Hệ số (chuẩn hóa) | Hệ số  |
|------|-----------------|-------------------|--------|
| 1    | worst texture   | +0.6235           | 0.6235 |
| 2    | worst radius    | +0.5081           | 0.5081 |
| 3    | radius error    | +0.4863           | 0.4863 |
| 4    | worst area      | +0.4641           | 0.4641 |
| 5    | worst perimeter | +0.4617           | 0.4617 |
| 6    | worst symmetry  | +0.4521           | 0.4521 |

| Hạng | Đặc trưng            | Hệ số (chuẩn hóa) | Hệ số  |
|------|----------------------|-------------------|--------|
| 7    | mean concave points  | +0.4480           | 0.4480 |
| 8    | worst concave points | +0.4430           | 0.4430 |
| 9    | mean texture         | +0.4235           | 0.4235 |
| 10   | worst concavity      | +0.3737           | 0.3737 |

**Bảng 07 - 10 đặc trưng có |hệ số| lớn nhất của Logistic Regression tốt nhất (outputs/07\_logistic\_coefficients.csv).**

Toàn bộ 10 hệ số lớn nhất đều mang dấu dương, nghĩa là khi các đặc trưng này (đã chuẩn hóa) tăng, log-odds của việc là malignant cũng tăng — phù hợp với hiểu biết y khoa rằng khối u ác tính thường có kích thước lớn hơn, bề mặt kém đồng đều hơn (texture cao hơn) và nhiều điểm lõm hơn (concave points) so với khối u lành tính. Đây chỉ là mối liên hệ thống kê trong một mô hình tuyến tính đã chuẩn hóa, không được diễn giải là quan hệ nhân quả sinh học; đồng thời do nhiều đặc trưng hình học có tương quan cao với nhau (Mục 1, Hình 04), độ lớn hệ số của từng đặc trưng riêng lẻ có thể bị ảnh hưởng bởi các đặc trưng tương quan đi kèm.

## 6.2. Cây quyết định và feature importance



**Hình 11 - Decision Tree tốt nhất, chỉ hiển thị 4 tầng đầu (cây thật sâu 7 tầng) (outputs/11\_decision\_tree.png).**

| Hạng | Đặc trưng (Decision Tree) | Importance | Đặc trưng (Random Forest) | Importance |
|------|---------------------------|------------|---------------------------|------------|
| 1    | worst perimeter           | 0.7670     | worst area                | 0.1529     |
| 2    | worst concave points      | 0.0979     | worst concave points      | 0.1345     |
| 3    | worst texture             | 0.0463     | worst radius              | 0.1004     |
| 4    | mean area                 | 0.0299     | worst perimeter           | 0.0876     |
| 5    | worst area                | 0.0213     | mean concave points       | 0.0837     |

**Bảng 12/14 - 5 đặc trưng quan trọng nhất theo Decision Tree và Random Forest (outputs/12\_tree\_feature\_importance.csv, outputs/14\_forest\_feature\_importance.csv; tổng importance mỗi bảng ≈ 1.0000).**

Decision Tree gần như chỉ dựa vào một đặc trưng duy nhất, worst perimeter (importance = 0.767), cho lần chia đầu tiên (và quan trọng nhất) — đặc trưng có tương quan cao với target (Mục 1). Random Forest phân bổ importance đều hơn giữa nhiều đặc trưng (worst area 0.153, worst concave points 0.135, worst radius 0.100...) nhờ cơ chế chọn ngẫu nhiên tập con đặc trưng tại mỗi lần chia (max\_features), khiến các cây con trong rừng không luôn dựa vào cùng một đặc trưng mạnh nhất. Feature importance của cây đo mức độ đặc trưng đó góp phần giảm độ hỗn loạn (Gini) qua các lần chia, luôn không âm và không cho biết chiều ảnh hưởng (tăng hay giảm khả năng malignant) như hệ số Logistic; hai đại lượng này vì vậy không nên so sánh trực tiếp như cùng một loại thước đo (xem câu trả lời 10, Phụ lục). Ngoài ra, feature importance có thể bị pha loãng giữa các đặc trưng tương quan cao với nhau, nên không được diễn giải là quan hệ nhân quả.

## 7. Kết luận

Mô hình được khuyến nghị là Logistic Regression (Pipeline StandardScaler → LogisticRegression(C=0.1, penalty='l2', class\_weight='balanced')), do đạt F1 CV cao nhất trên tập train (0.9674) theo đúng quy tắc lựa chọn đã công bố, và kết quả này được xác nhận nhất quán khi đánh giá một lần trên tập test độc lập: F1 = 0.9880, ROC-AUC = 0.9977, chỉ bỏ sót 1/42 ca malignant (FN = 1) — thấp nhất trong bốn mô hình. Lý do lựa chọn không chỉ dựa trên hiệu năng cao nhất mà còn vì mô hình có độ ổn định tốt nhất giữa các fold (std F1 CV thấp nhất), chi phí huấn luyện/dự đoán rất thấp, và có khả năng giải thích trực tiếp qua hệ số hồi quy — phù hợp với bối cảnh hỗ trợ chẩn đoán y khoa, nơi khả năng diễn giải kết quả cũng quan trọng không kém độ chính xác.

Hạn chế: (1) tập test chỉ có 114 mẫu, nên chênh lệch nhỏ về F1 giữa Logistic Regression và kNN (0.9674 so với 0.9667 ở CV) chưa đủ để khẳng định chắc chắn ý nghĩa thống kê; (2) không gian tìm kiếm siêu tham số tuy khá rộng nhưng vẫn hữu hạn và rời rạc, có thể chưa bao phủ cấu hình tối ưu tuyệt đối; (3) dữ liệu vẫn còn mất cân bằng lớp nhẹ, và dù class\_weight='balanced' đã được cân nhắc trong lưới tìm kiếm, vẫn còn 1 ca malignant bị bỏ sót trên tập test.

Hướng cải tiến: áp dụng nested cross-validation hoặc lặp lại toàn bộ quy trình với nhiều random\_state khác nhau để ước lượng độ ổn định của việc lựa chọn mô hình một cách đáng tin cậy hơn; đồng thời có thể thử nghiệm thêm việc điều chỉnh ngưỡng xác suất phân loại (threshold tuning) thay vì cố định ở 0.5, nhằm ưu tiên giảm hơn nữa số FN (tăng Recall malignant) ở mức đánh đổi Precision có thể chấp nhận được trong bối cảnh sàng lọc y khoa.

## Phụ lục - Trả lời 10 câu hỏi bắt buộc

### 1. Vì sao phải mã hóa malignant thành lớp 1 trước khi dùng Precision, Recall và F1 mặc định?

Các hàm `precision_score`, `recall_score`, `f1_score` của Scikit-learn mặc định coi nhãn 1 là lớp dương (`pos_label=1`). Vì bài toán quan tâm đến khả năng phát hiện đúng ca malignant, cần mã hóa malignant = 1 để các chỉ số mặc định phản ánh đúng khả năng phát hiện lớp mục tiêu lâm sàng, tránh nhầm lẫn khi diễn giải kết quả.

### 2. Vì sao Logistic Regression và kNN cần StandardScaler, còn Decision Tree và Random Forest thường không cần?

Logistic Regression tối ưu qua gradient trên một tổ hợp tuyến tính có trọng số của đặc trưng, còn kNN dựa trực tiếp trên khoảng cách giữa các điểm; nếu các đặc trưng có thang đo khác nhau, đặc trưng có giá trị lớn sẽ chi phối kết quả. Ngược lại, cây quyết định và Random Forest chia dữ liệu dựa trên ngưỡng của từng đặc trưng riêng lẻ, không dựa trên khoảng cách hay tổ hợp tuyến tính theo thang đo, nên cơ giãn tuyến tính của một đặc trưng không ảnh hưởng đến thứ tự các điểm chia.

### 3. C trong Logistic Regression ảnh hưởng regularization như thế nào?

C là nghịch đảo cường độ điều chuẩn. C nhỏ tăng độ mạnh điều chuẩn, ép hệ số về gần 0, giúp mô hình đơn giản, giảm overfitting nhưng có thể underfitting nếu quá nhỏ. C lớn giảm điều chuẩn, cho phép hệ số lớn tự do khớp dữ liệu train hơn, có thể tăng nguy cơ overfitting.

### 4. k nhỏ và k lớn ảnh hưởng bias, variance và biên quyết định của kNN ra sao?

k nhỏ tạo biên quyết định phức tạp, uốn lượn sát từng điểm dữ liệu, variance cao và bias thấp (dễ overfitting, nhạy nhiễu). k lớn tạo biên quyết định mượt hơn, bias cao và variance thấp hơn (dễ underfitting, bỏ qua cấu trúc cục bộ), vì mỗi dự đoán được trung bình hóa qua nhiều láng giềng hơn.

### 5. max\_depth và min\_samples\_leaf kiểm soát overfitting của Decision Tree như thế nào?

`max_depth` giới hạn số tầng phân chia tối đa, ngăn cây phát triển quá sâu để học thuộc từng mẫu train. `min_samples_leaf` quy định số mẫu tối thiểu phải có tại mỗi lá, ngăn cây tạo ra các lá chỉ chứa một vài mẫu đặc biệt (dễ là nhiễu). Cả hai đều là cơ chế cắt tỉa sớm (pre-pruning) giúp cây tổng quát hóa tốt hơn thay vì ghi nhớ dữ liệu train.

### 6. Random Forest giảm nhược điểm nào của một cây đơn? Vai trò của n\_estimators và max\_features là gì?

Random Forest giảm phương sai cao (overfitting) vốn là nhược điểm chính của một cây quyết định đơn, bằng cách kết hợp (bagging) nhiều cây được huấn luyện trên các mẫu bootstrap và tập con đặc trưng ngẫu nhiên khác nhau, sau đó lấy kết quả trung bình/đa số. `n_estimators` là số lượng cây trong rừng — càng nhiều cây thường càng ổn định (giảm phương sai) nhưng tăng chi phí tính toán. `max_features` giới hạn số đặc trưng được xét tại mỗi lần chia của mỗi cây, làm giảm tương quan giữa các cây, qua đó tăng hiệu quả giảm phương sai khi tổng hợp kết quả.

## **7. Tại sao không được chọn mô hình bằng kết quả test?**

Nếu dùng kết quả trên tập test để chọn mô hình hoặc điều chỉnh siêu tham số, tập test không còn đóng vai trò là dữ liệu chưa từng thấy một cách khách quan nữa, mà gián tiếp trở thành một phần của quá trình huấn luyện/lựa chọn mô hình. Điều này khiến chỉ số đánh giá trên test bị lạc quan hơn khả năng thực sự của mô hình khi triển khai trên dữ liệu mới.

## **8. Accuracy cao có thể che giấu vấn đề gì khi malignant là lớp ít hơn?**

Khi malignant là lớp thiểu số, một mô hình thiên vị dự đoán benign cho hầu hết các mẫu vẫn có thể đạt Accuracy khá cao (xấp xỉ tỷ lệ lớp đa số) dù Recall của lớp malignant rất thấp, tức mô hình bỏ sót phần lớn ca bệnh thực sự. Accuracy cao trong trường hợp này che giấu hiệu năng kém trên lớp thiểu số — lớp quan trọng nhất trong bài toán chẩn đoán.

## **9. FN và FP có ý nghĩa gì trong bài toán này? Sai lầm nào đáng lo hơn và vì sao?**

FN (false negative) là trường hợp một ca thực sự malignant bị dự đoán nhầm thành benign — bệnh nhân ung thư có thể không được điều trị kịp thời. FP (false positive) là trường hợp một ca thực sự benign bị dự đoán nhầm thành malignant — bệnh nhân phải chịu thêm xét nghiệm hoặc lo lắng không cần thiết nhưng không nguy hiểm đến tính mạng. FN đáng lo hơn nhiều vì hậu quả y khoa của việc bỏ sót ung thư nghiêm trọng hơn hẳn chi phí của một lần xét nghiệm/chẩn đoán bổ sung.

## **10. Hệ số Logistic và feature importance của cây khác nhau về ý nghĩa như thế nào?**

Hệ số của Logistic Regression (trên dữ liệu đã chuẩn hóa) thể hiện mức độ và chiều ảnh hưởng tuyến tính của một đặc trưng lên log-odds của lớp dương, có dấu (dương/âm) và diễn giải trực tiếp theo hướng tăng/giảm. Feature importance của cây quyết định/Random Forest đo mức độ đặc trưng đó góp phần giảm độ hỗn loạn (Gini) qua tất cả các lần chia, luôn không âm và không cho biết chiều ảnh hưởng, đồng thời có thể bị ảnh hưởng bởi các đặc trưng tương quan cao với nhau. Hai đại lượng này không thể so sánh trực tiếp như cùng một loại thước đo.